APRENDIZADO DE MÁQUINA SUPERVISIONADO

PROADMI - Contratos

Johnny Cleiton | Joss Timoteo | Raphael Feitosa

Report Experimental

Este trabalho aborda um problema de classificação supervisionada de contratos públicos, com o objetivo de classificá-los por unidade gestora com base em características como valor, duração, datas e descrição do objeto.

Objetivo: como a unidade gestora é um atributo administrativo e não causal (ou seja, não é uma variável que seja determinada pelas demais), o foco é avaliar a capacidade dos modelos em identificar padrões nos dados para realizar essa classificação.

Dataset:

- Dados de Contratos de 2024 do Tribunal de Contas do Estado de Pernambuco (disponíveis no Portal da Transparência)
- Aproximadamente 2047 registros
- 11 variáveis

ug	Unidade gestora responsável pelo contrato
contrato_ano	Ano de referência do contrato
objeto	Descrição do objeto/serviço do contrato
situacao	Situação atual do contrato (ex: ativo, encerrado)
estagio	Etapa do contrato dentro do processo administrativo
processo	Identificador do processo administrativo
fornecedor	Empresa ou pessoa contratada
data_inicio_vigencia	Data de início da vigência do contrato
data_fim_vigencia	Data de término da vigência do contrato
valor	Valor financeiro do contrato
download	Indica ou contém link para acesso ao documento do contrato

1. Análise dos Dados

Foram realizadas análises descritivas básicas para compreender a distribuição das variáveis e identificar possíveis valores faltantes.

	situacao	valor
count	0.00	2047.00
mean	NaN	856633.72
std	NaN	8316146.61
min	NaN	49.38
25%	NaN	10958.00
50%	NaN	30000.00
75%	NaN	98500.00
max	NaN	246918126.00

```
Data columns (total 11 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
 0   ug                    2047 non-null   object
 1   contrato_ano          2047 non-null   object
 2   objeto                2047 non-null   object
 3   situacao              0 non-null      float64
 4   estagio               2047 non-null   object
 5   processo              982 non-null    object
 6   fornecedor            2047 non-null   object
 7   data_inicio_vigencia  2047 non-null   object
 8   data_fim_vigencia     2047 non-null   object
 9   valor                 2047 non-null   float64
 10  download              2036 non-null   object
```

Insights:

- A variável *"situacao"* não apresentou valores numéricos, todos NaN. E a variável *"processo"* possui poucos campos preenchidos considerando o total.
- Contagem (count) de 2047 contratos com valor válido, então não há valor de contrato faltando, assim como outras informações importantes.
- A média (mean = 856.633) é significativamente maior que a mediana (50% = 30.000).

O valor dos contratos varia de R$ 49,38 a R$ 246.918.100, e a diferença entre média e mediana indica a presença de outliers. Por isso, foi utilizado um boxplot em escala logarítmica para melhor visualizar a distribuição da variável valor.

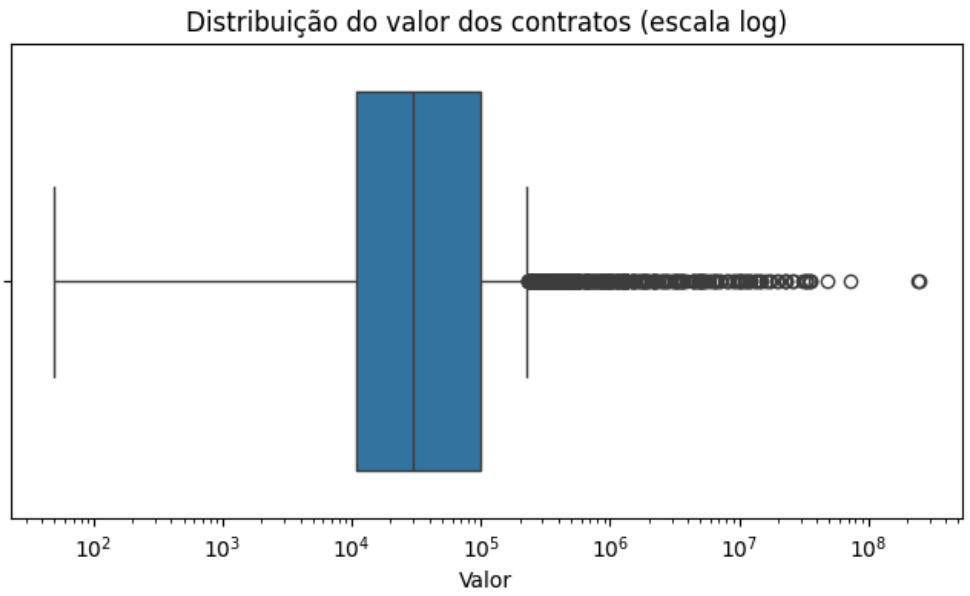

Existem muitos contratos com valores bem acima do padrão, que fogem do valor de 100 mil (10^5). A mediana se confirma por estar entre 30 mil (10^4) e 100 mil (10^5).

2. Metodologia

Pré-processamento

Com base nas informações da análise descritiva, optamos pela remoção das seguintes features:

- *"situacao"* - removida por ausência total de dados, não contribuindo para o modelo;
- *"processo"* - removida por alta quantidade de valores ausentes;
- *"download"* - removida por não possuir valor informativo para a tarefa de classificação.

Transformação de dados:

- Conversão de colunas de data para datetime e extração de features numéricas;
- Criação de uma coluna para a duração do contrato em dias;
- Conversão de "*contrato_ano*" para numérico, extraindo apenas o ano;
- Conversão de variáveis categóricas em numéricas ("*ug*", "*objeto*", "*estagio*" e "*fornecedor*").

```
Data columns (total 13 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   valor                     2045 non-null   float64
 1   data_inicio_vigencia_ano  2045 non-null   int32
 2   data_inicio_vigencia_mes  2045 non-null   int32
 3   data_inicio_vigencia_dia  2045 non-null   int32
 4   data_fim_vigencia_ano     2045 non-null   float64
 5   data_fim_vigencia_mes     2045 non-null   float64
 6   data_fim_vigencia_dia     2045 non-null   float64
 7   duracao_dias              2045 non-null   float64
 8   ano_contrato              2045 non-null   float64
 9   ug_num                    2045 non-null   int64
 10  objeto_num                2045 non-null   int64
 11  estagio_num               2045 non-null   int64
 12  fornecedor_num            2045 non-null   int64
```

De acordo com a Matriz de Correlação em anexo, decidimos por fazer a remoção de features com correlação baixa com "*ug_num*", sendo elas: *"ano_contrato",* "*data_inicio_vigencia_ano*", "*data_inicio_vigencia_dia*", "*data_fim_vigencia_dia*" e "*estagio_num*".

```
Data columns (total 8 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   valor                     2045 non-null   float64
 1   data_inicio_vigencia_mes  2045 non-null   int32
 2   data_fim_vigencia_ano     2045 non-null   float64
 3   data_fim_vigencia_mes     2045 non-null   float64
 4   duracao_dias              2045 non-null   float64
 5   ug_num                    2045 non-null   int64
 6   objeto_num                2045 non-null   int64
 7   fornecedor_num            2045 non-null   int64
```

Divisão de treino/teste:
A variável alvo é a "*ug_num*" e as demais são as entradas dos modelos.

	número de amostras	número de features
Treino (60%)	1227	8
Validação (20%)	409	8
Teste (20%)	409	8

1227 + 409 + 409 = 2045 (~2047 do dataset)

O conjunto de treino foi utilizado para o aprendizado dos modelos, o de validação para ajuste de parâmetros e o de teste para avaliação final de desempenho.

Modelos de Aprendizado de Máquina Supervisionado:
A fim de comparar abordagens distintas de aprendizado, foram aplicados diferentes modelos de classificação supervisionada:

- **Regressão Logística -** modelo linear amplamente utilizado como baseline em tarefas de classificação, por sua simplicidade, interpretabilidade e eficiência. Ela estima a probabilidade de pertencimento a cada classe com base em uma combinação linear das variáveis de entrada.
- **MLP (Multi-Layer Perceptron)** - modelo de rede neural artificial composto por múltiplas camadas de neurônios. Ele é capaz de capturar relações não lineares entre as variáveis, tornando-se mais flexível que modelos lineares, embora exija maior custo computacional.
- **CNN (Convolutional Neural Network)** - tipo de rede neural que utiliza operações de convolução para extrair padrões nos dados. Embora seja mais comum em dados estruturados como imagens, sua aplicação neste contexto busca avaliar sua capacidade de capturar padrões mais complexos nas variáveis.

Métricas de Avaliação
Para avaliar o desempenho dos modelos, foram utilizadas diferentes métricas de classificação:

- **Accuracy (acurácia)** - mede a proporção de previsões corretas em relação ao total de amostras, sendo uma métrica geral de desempenho.
- **Precision (precisão)** - indica a proporção de previsões positivas que estão corretas, sendo importante quando há preocupação com falsos positivos.
- **Recall (revocação)** - mede a capacidade do modelo de identificar corretamente as instâncias positivas, sendo relevante quando se deseja minimizar falsos negativos.
- **F1-score** - é a média harmônica entre precisão e recall, fornecendo uma medida equilibrada entre ambas, especialmente útil em cenários com classes desbalanceadas.

3. Resultados

Abaixo tem a tabela de comparação entre os resultados dos treinamentos dos três modelos. A comparação permite analisar o desempenho de cada abordagem na tarefa de classificação proposta.

Modelo	Accuracy	Precision	Recall	F1
Regressão Logística	0.706601	0.175058	0.198806	0.177097
MLP	0.696822	0.168828	0.186218	0.163425
CNN	0.735941	0.255854	0.257735	0.238973

4. Conclusão

Os resultados indicam que o modelo de **CNN** apresentou o melhor desempenho geral entre os métodos avaliados, obtendo os maiores valores em todas as métricas, especialmente em acurácia (0,735941) e F1-score (0,238973). Isso sugere uma maior capacidade do modelo em capturar padrões mais complexos nos dados. Já a **Regressão Logística** e o **MLP** apresentaram desempenhos inferiores e relativamente próximos entre si.

Importante observar que as métricas de precisão, recall e F1-score são relativamente baixas para todos os modelos, o que pode indicar dificuldades na tarefa de classificação, possivelmente relacionadas ao desbalanceamento das classes ou à complexidade dos dados.

Em resumo: embora a **CNN** tenha se destacado, os resultados sugerem que ainda há espaço para melhorias, seja por meio de melhor tratamento dos dados, engenharia de atributos ou ajuste mais refinado dos modelos.

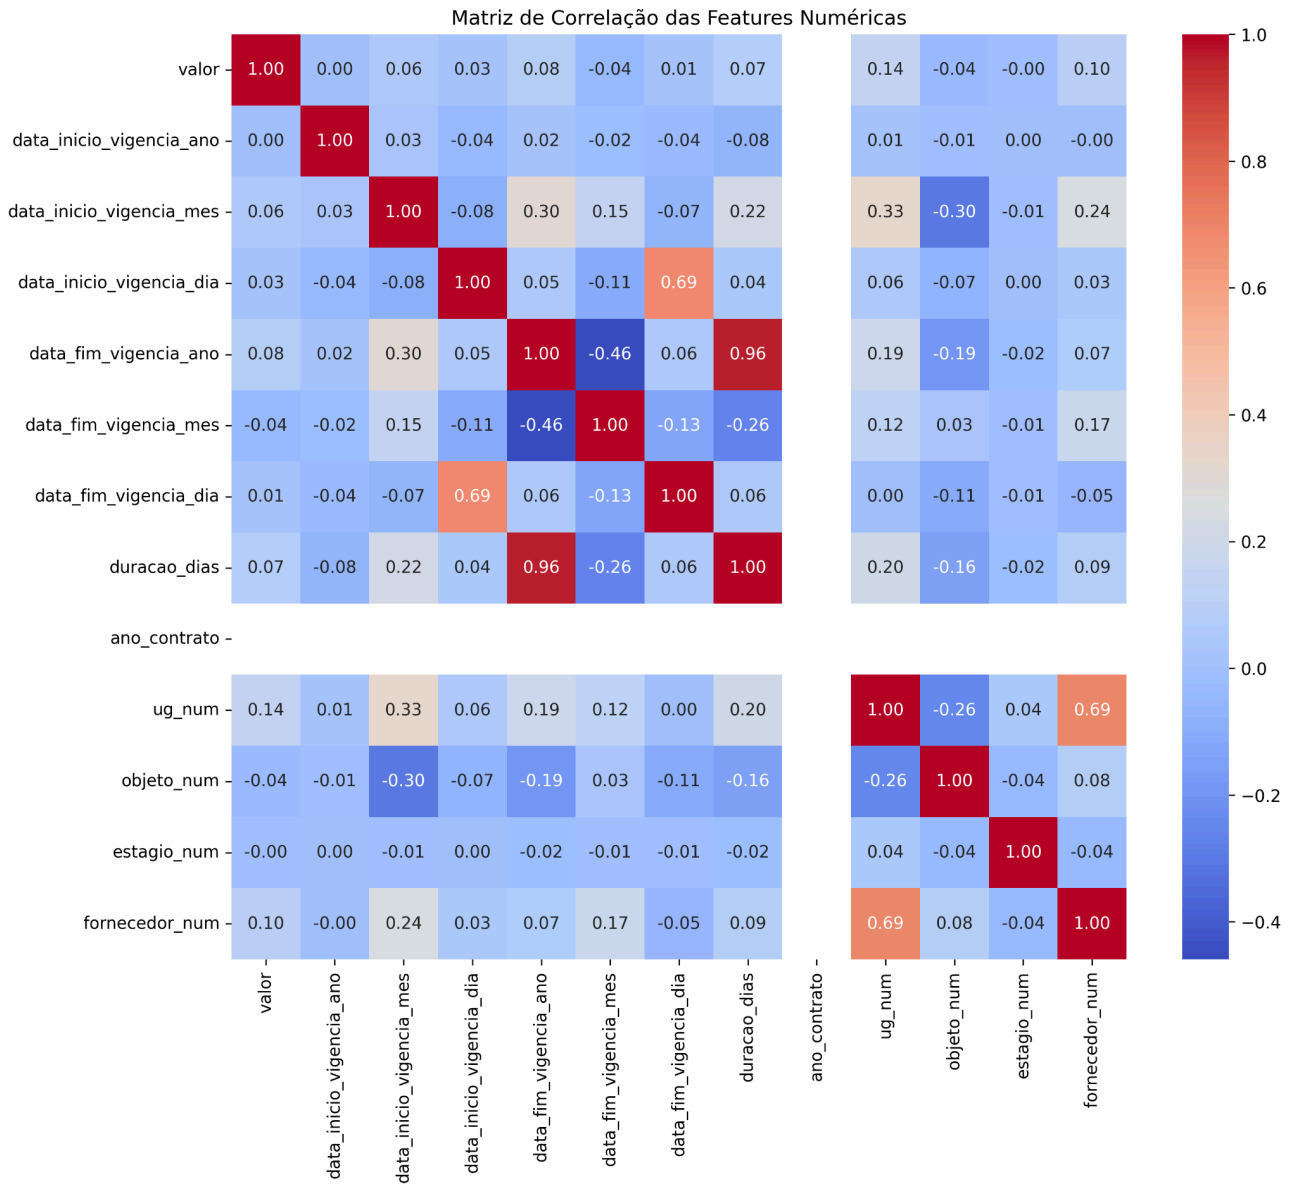
Matriz de Correlação das Features Numéricas
valor
data_inicio_vigencia_ano
data_inicio_vigencia_mes
data_inicio_vigencia_dia
data_fim_vigencia_ano
data_fim_vigencia_mes
data_fim_vigencia_dia
duracao_dias
ano_contrato
ug_num
objeto_num
estagio_num
fornecedor_num
1.0
0.8
0.6
0.4
0.2
0.0
−0.2
−0.4