Especialização em Ciência de Dados e Analytics

Soluções para Processamento de Big Data

{ Clusters e mais… }

Prof. Jairson Rodrigues
jairson.rodrigues@univasf.edu.br

{ contexto }

- Áreas de mercado e pesquisa complexas
  - Aeronáutica, previsão do tempo, pesquisa farmacêutica e biológica, modelagem populacional, sistemas complexos adaptativos
- Aplicações cada vez mais exigentes
- Necessidade crescente de processamento paralelo massivo
- Aumento da capacidade dos computadores comuns
- Surgimento dos Clusters
- Surgimento dos Grids

{ cluster }

AGENDA

- HPC
- Cluster
- GRID
- Nuvem

{ cluster }

- Nós (computadores mono ou multiprocessados) dentro de uma LAN de alta velocidade, que funcionam como um único computador paralelo
- Computação em Cluster permite que vários computadores trabalhem juntos para resolver problemas complexos de grande porte

{ cluster }

- Componentes relativamente baratos
- Reduz custo de construção comparado com único computador paralelo de mesma capacidade
- Alto Desempenho e/ou Disponibilidade e/ou Processamento
- Maior escalabilidade que o multiprocessamento
  - Supercomputador HP 9000 Superdome: até 64 processadores
  - Cluster HP XC: até 512 processadores
  - Cluster Beowulf: até 700 processadores

{ cluster beowulf }

- Criado por Donald Becker, da NASA baseado em PC's
- Idealizado para suprir demanda por elevada capacidade de processamento (HPC) a custos economicamente viáveis
- Motivação
  - Aumento da performance computacional de PC's
  - Preço decrescente versus poder computacional crescente
  - Utiliza software gratuito de elevado desempenho: Linux/FreeBSD

{ cluster beowulf }

{ cluster da google (2008) ** }

- Estimando… (George Couloris et al, Distributed Systems, Concepts and Design – Fifth Edition, dados de 2008)
  - 1 PC = 2 Terabytes
  - 1 hack de 80 PC's = 160 Terabytes
  - 1 cluster de 30 hacks = 4.8 Petabytes
- Estima-se que a Google possua 200 clusters
  - Capacidade de armazenamento próxima de 1 Exabyte = 1.099.511.627.776 Megabytes (1 trilhão de Megabytes)

** A Google não divulga detalhes de sua arquitetura, há muitas fontes na WEB que detalham a capacidade do cluster da Google, entretanto são apenas estimativas. O dado apresentado acima foi retirado de material acadêmico/universtiário, entretanto encontra-se defasado. A capacidade atual (2017) é superior ao apresentado.

{ cluster da google }

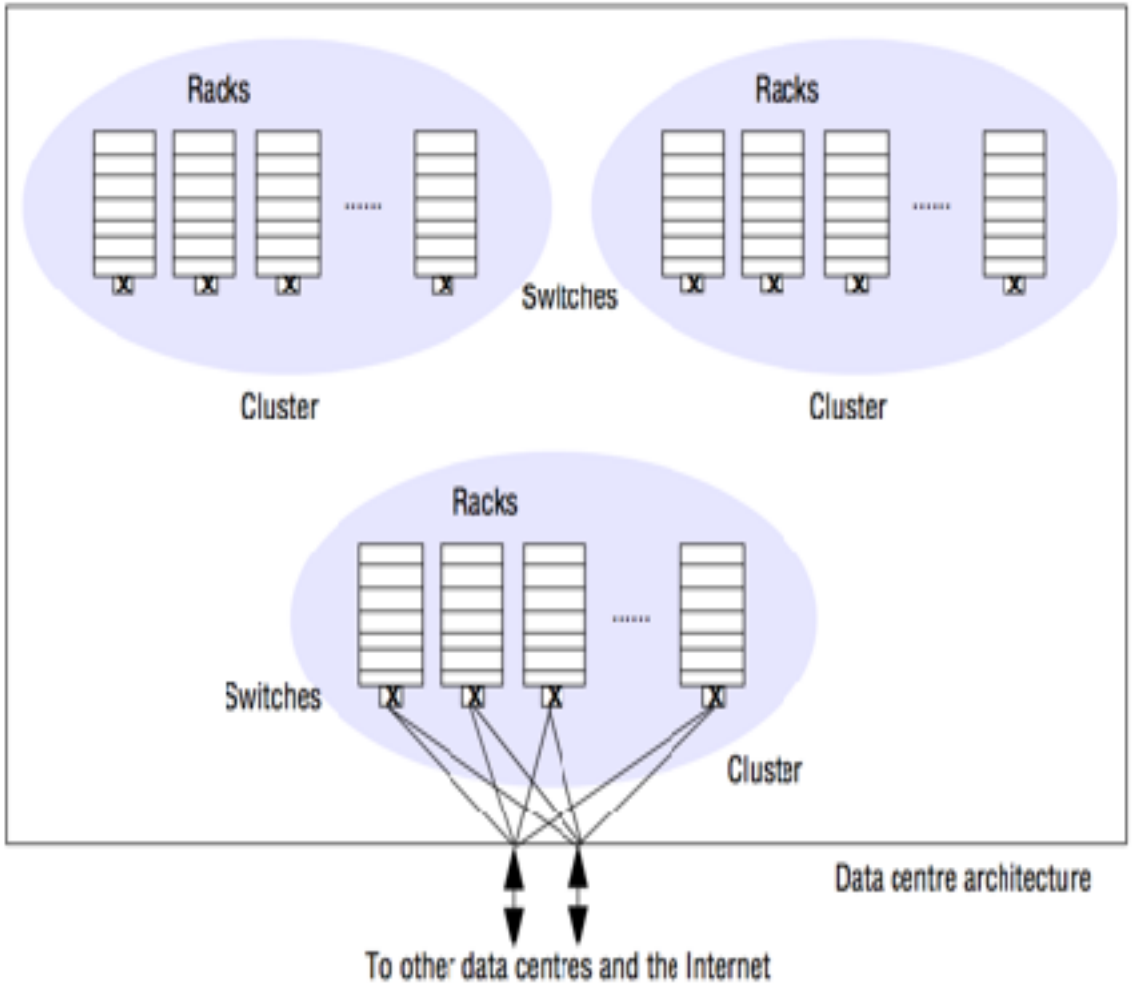

{ grids }

grande
Poli-UPE
variedade
MapReduce
Hadoop
inteligência
máquina
dados
aprendizagem
volume
Latu-Sensu
Especialização
Ciência
velocidade
vocabulário
análise
HDFS
validade
viralidade
valor

{ grids }

- A Internet
  - Sistemas totalmente heterogêneos
  - Fracamente acoplados
  - Geograficamente distribuídos
  - Com alto índice de máquinas ligadas e ociosas
- Grid
  - Compartilhamento de ciclos de CPU
  - Quando um computador não precisasse de todo seu poder computacional outros pudesse fazer uso de da CPU ociosa

{ grids }

- Primeiros projetos da década de 1990
  - FAFNER (Factoring via Network-Enabled Recursion)
  - I-WAY (Information Wide Area Year)
- A computação em Grid teve seu marco com o workshop "*Building a Computational Grid*", no Argonne National Laboratory, EUA, 1997

{ SETI@Home }

- Iniciado em 1996
- Acrônimo para Search for Extraterrestrial Intelligence
- Utiliza radio telescópios para “escutar” sinais vindos de fora do planeta
- Utiliza computação em Grid para analisar os dados
- Atualmente foi expandido para o projeto BOINC
- 4,109,949 hosts em Jan/2017 http://setiathome.berkeley.edu/stats.php

{ o grande colisor de hádrons }

- Há atividades computacionais que precisam de poder computacional inimaginável
- O LHC produz cerca de 41 TB de dados por dia; até 15 PB de dados por ano
- Seria necessário um cluster com ~100.000 CPUs

{ hpc / cluster / grid / cloud computing }

{ ... nesse contexto, anos 2000 }

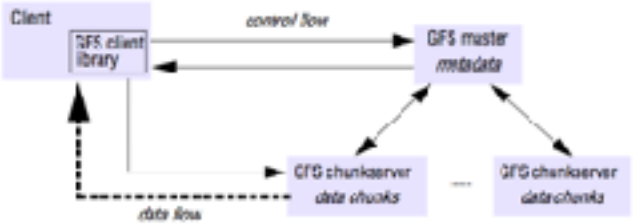

Google File System

Cluster Google

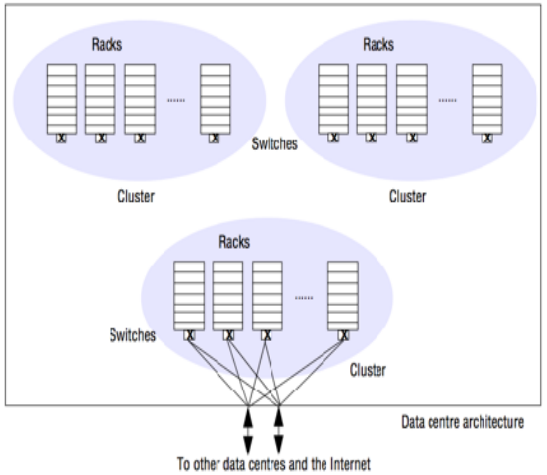

MapReduce

etc etc etc
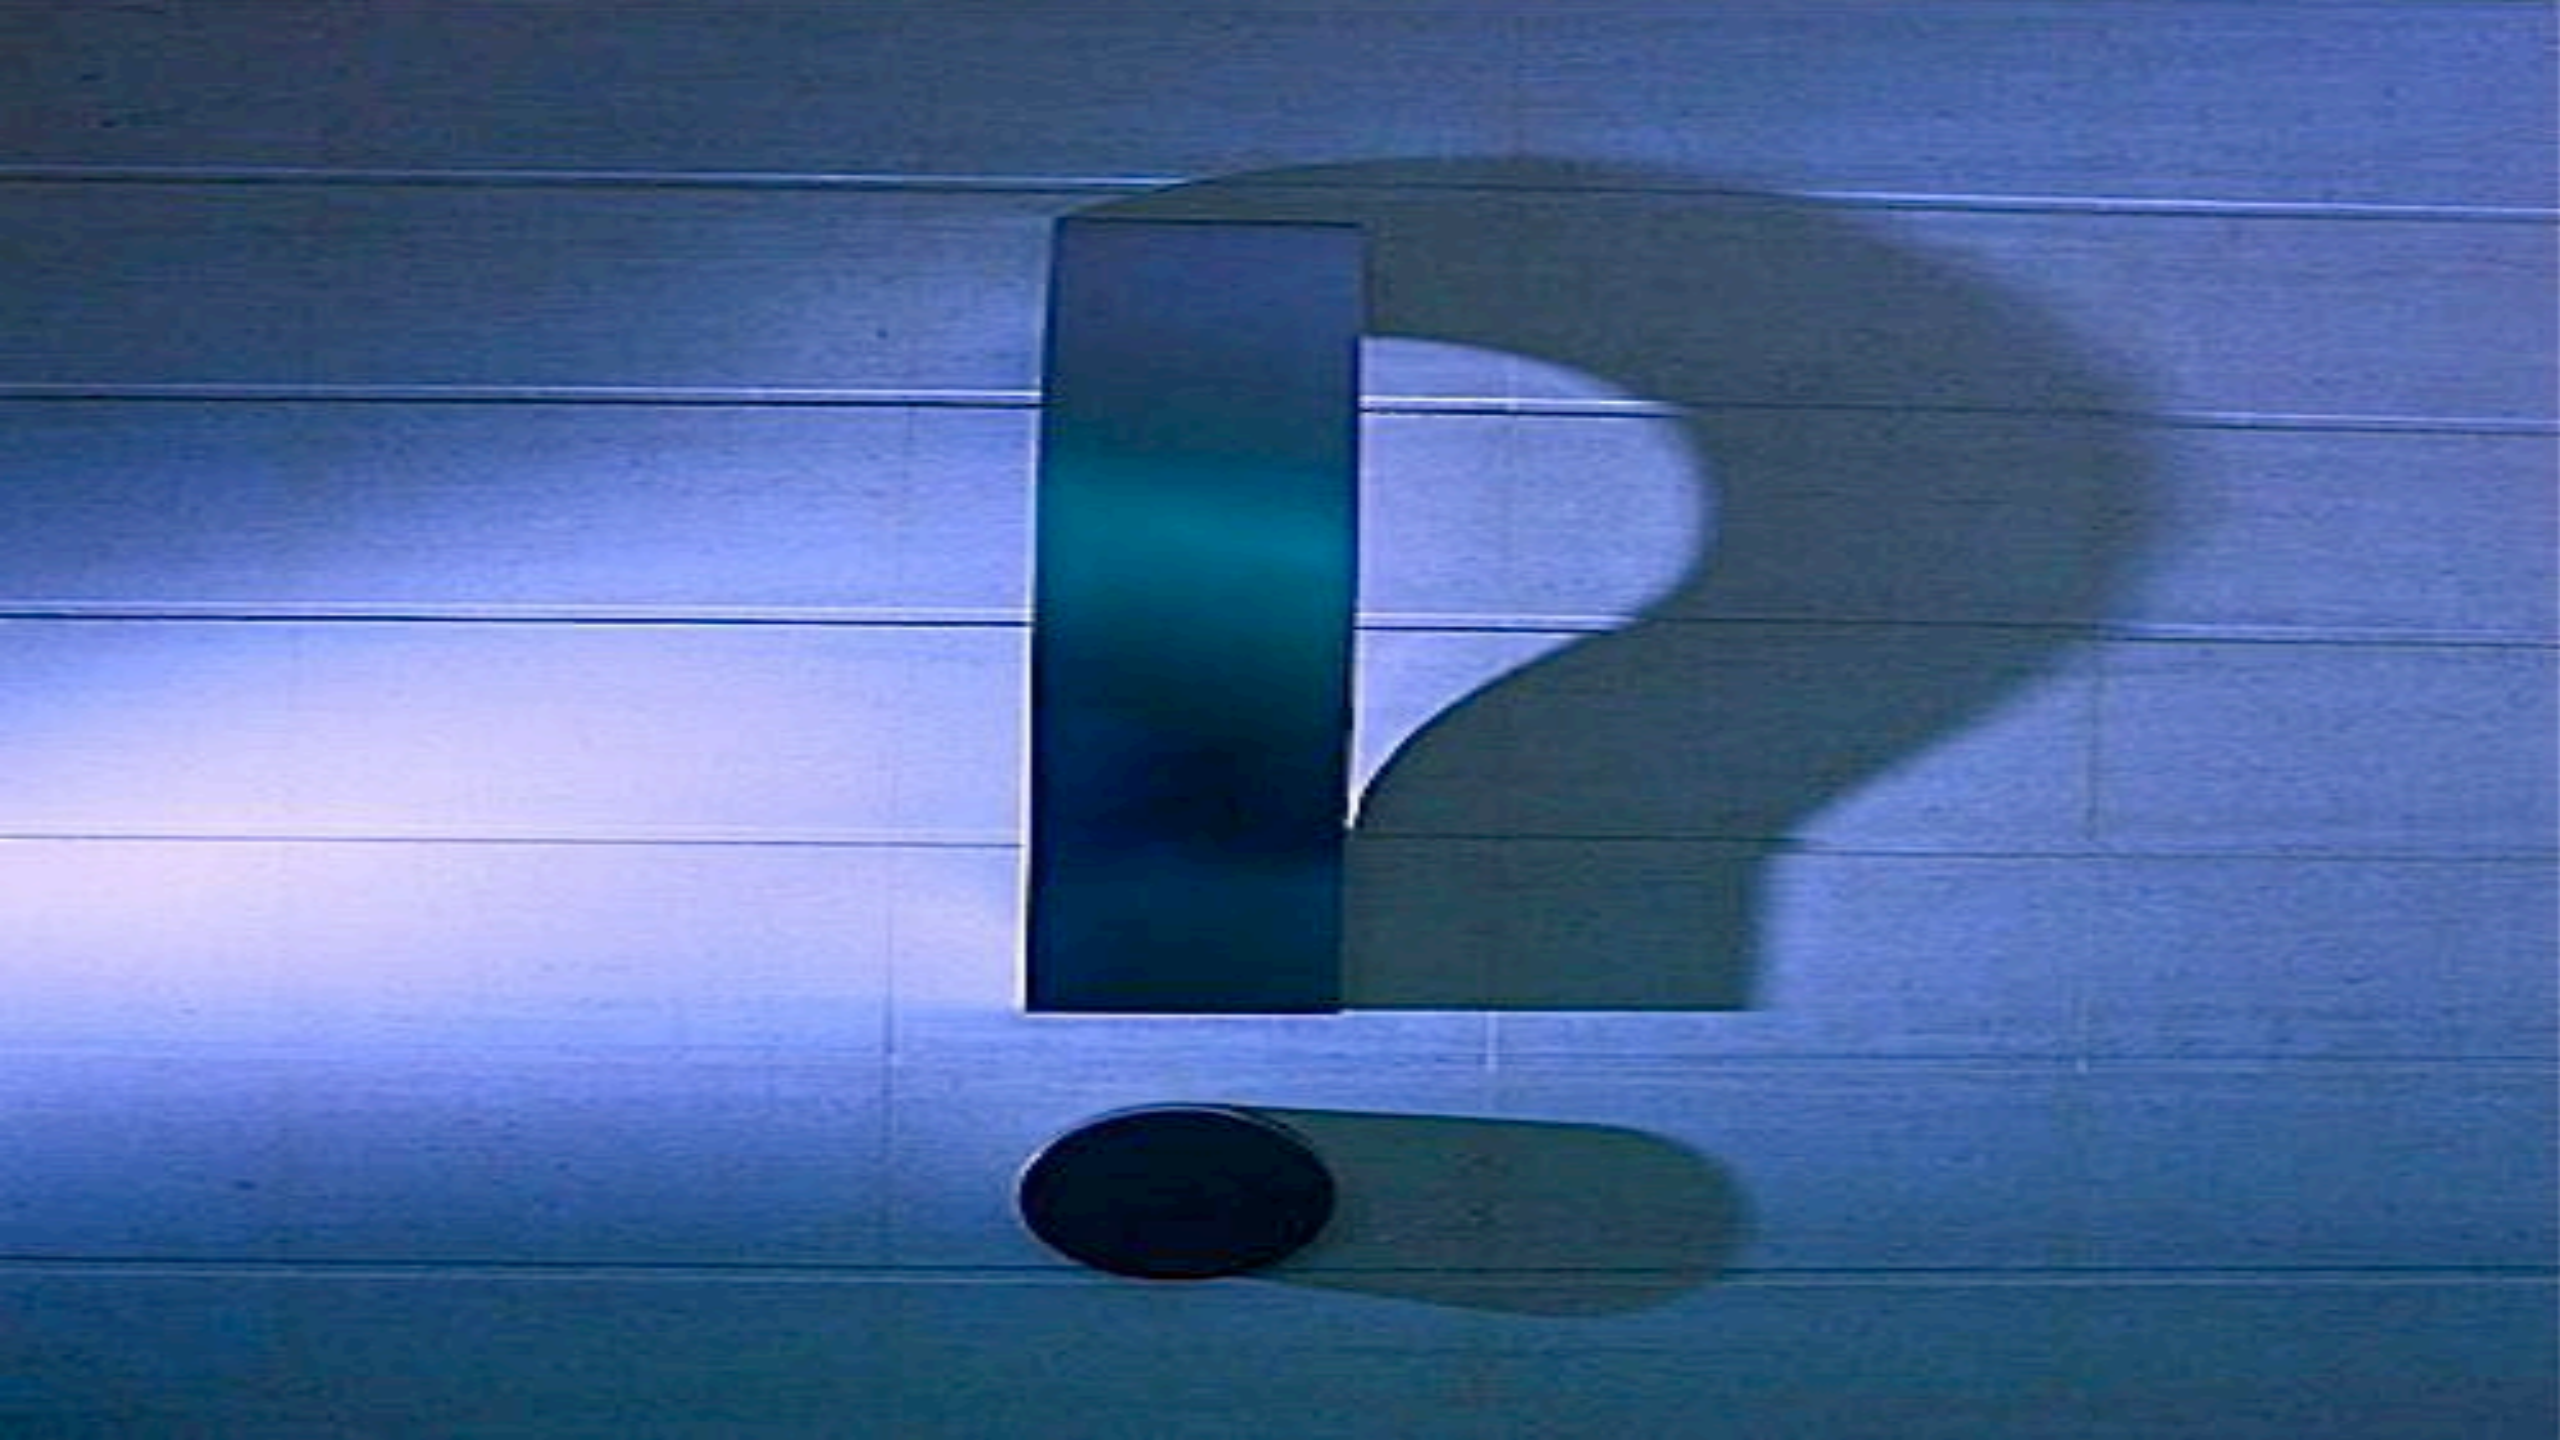
HDFS