Especialização em Ciência de Dados e Analytics

Soluções para Processamento de Big Data

{ HDFS | Prática }

Prof. Jairson Rodrigues
jairson.rodrigues@univasf.edu.br

{ roteiro }

- Interface Web
- Acesso remoto ao Namenode
- Principais comandos HDFS Shell
- Manipulação de arquivos
- Gerenciamento de réplicas
- Gerenciamento de tamanhos de bloco

{ nota }

Esta aula prática será concentrada na distribuição padrão Apache Hadoop 3.3.3 com acesso SSH via Namenode. Mas o aluno deve ter em mente que há muitas outras formas de acesso, por exemplo: WebHDFS ou opções proprietárias. Há produtos de mercado, tais como Cloudera, MapR e Hortonworks Sandbox, dentre outros, que fornecem clusteres em Docker/VirtualBox/VMWARE/KVM ou até mesmo interfaces para clusteres reais em provedores de computação em nuvem. Cada solução possui sua interface e forma de acesso próprios.

{ namenode - configuração e acesso remoto }

1. docker exec -it master /bin/bash
2. ./user_data/admin/fiat-lux.sh
3. ./user_data/admin/avertulux.sh

IMPORTANTE: os comandos 2 e 3 são scripts bash personalizados para a aula e não fazem parte da distribuição Hadoop ou Spark.

{ interface web }

http://loclhost:50070

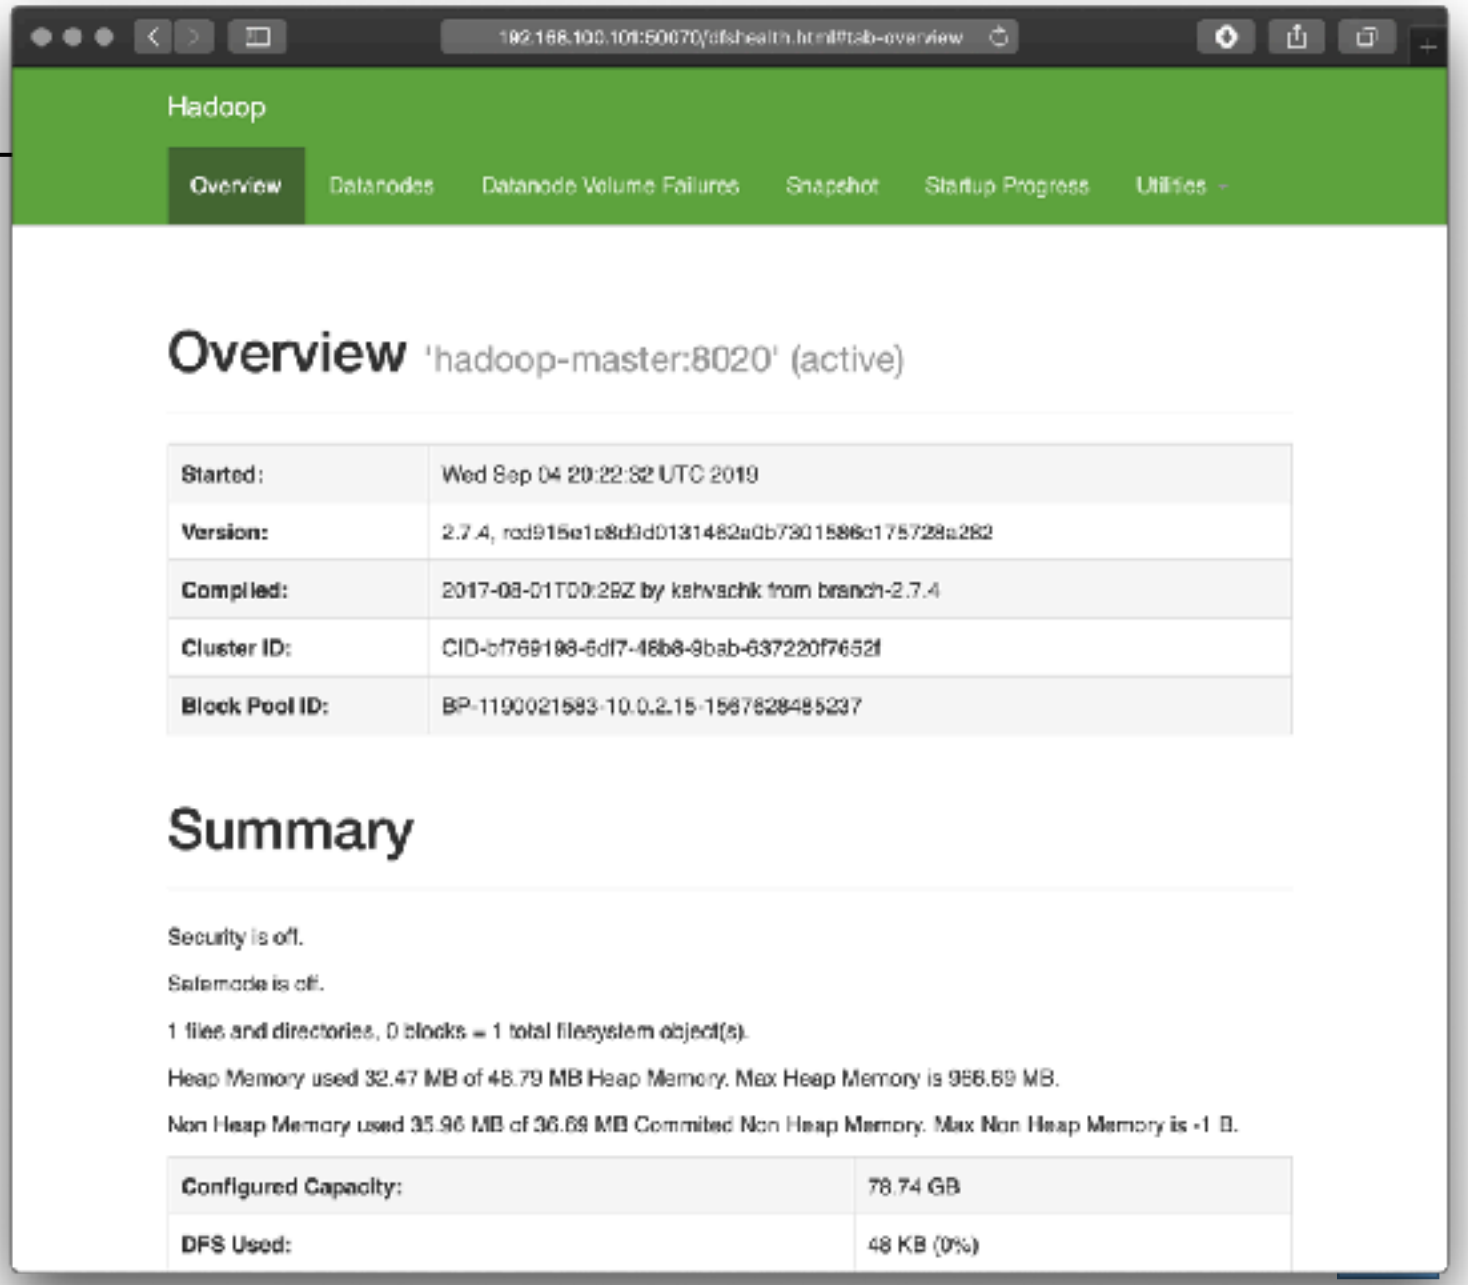

{ interface web }

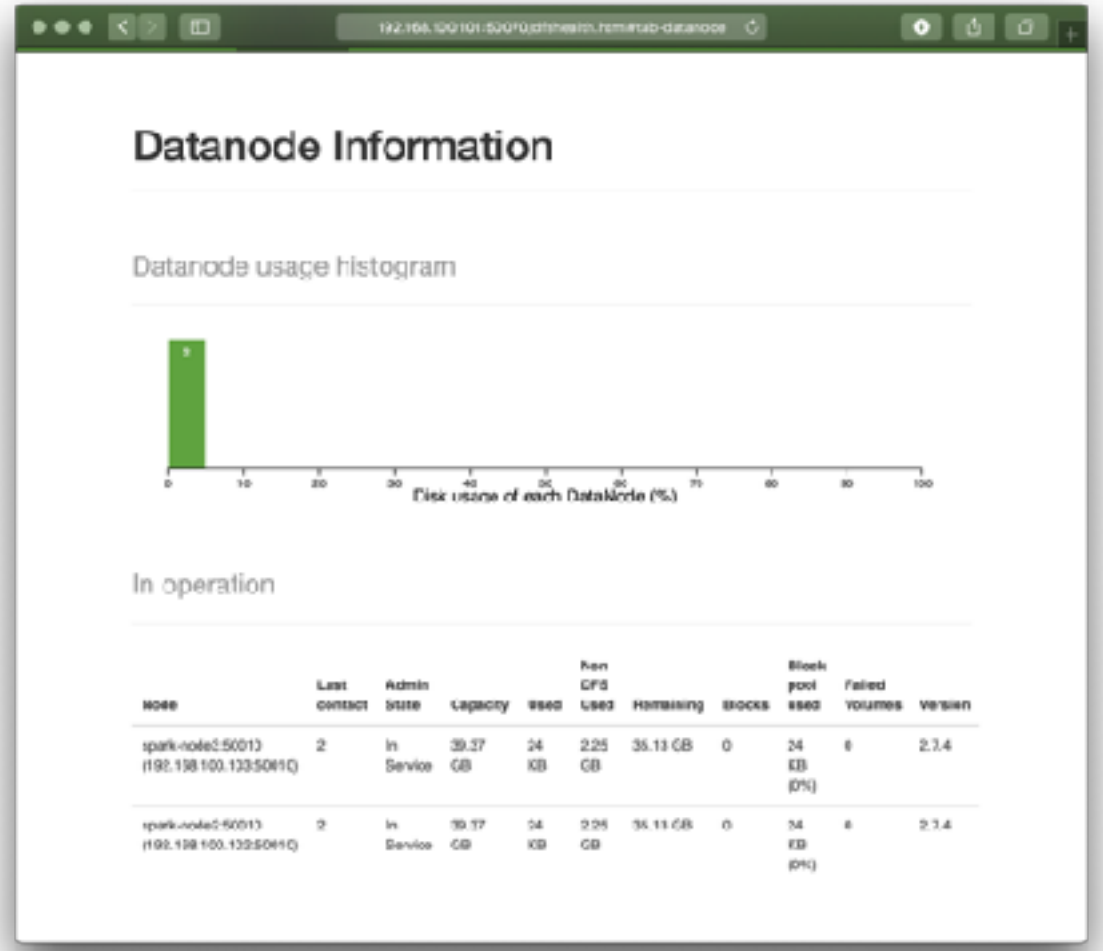

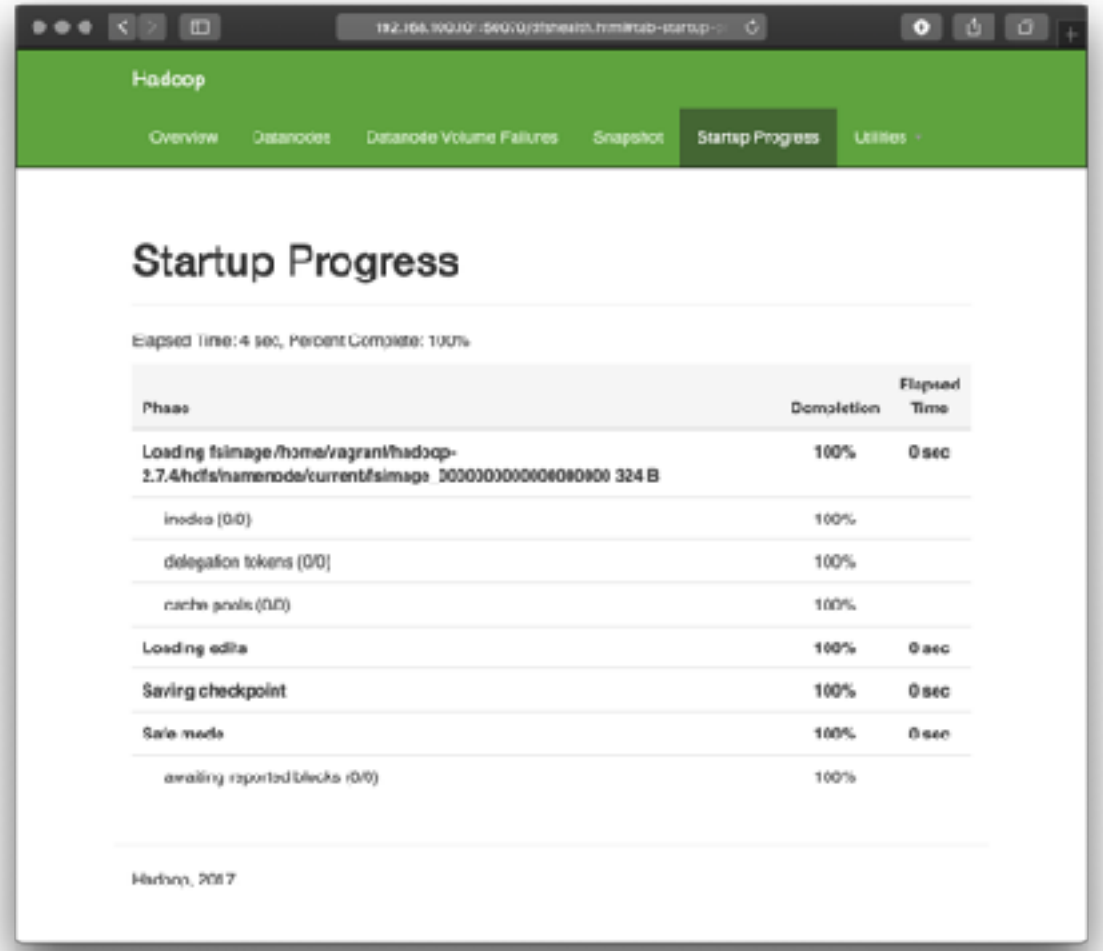

{ interface web }

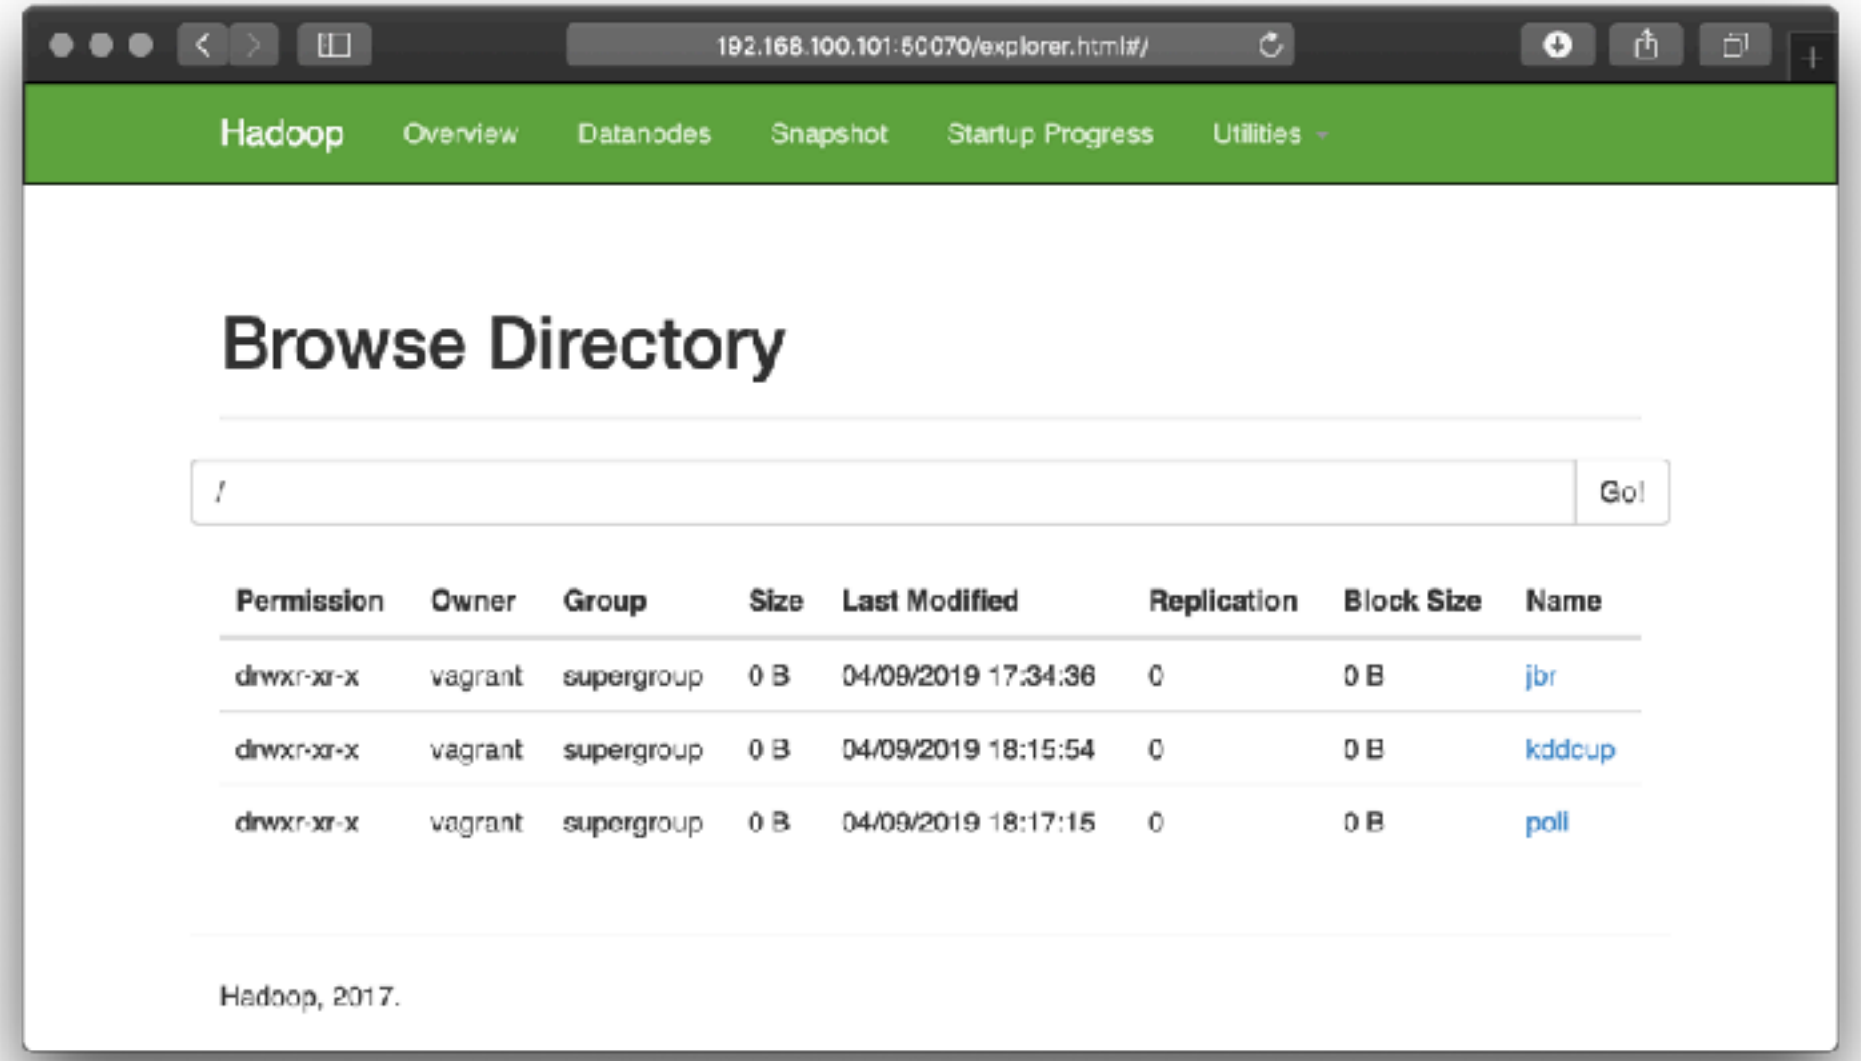

{ hadoop web interface }

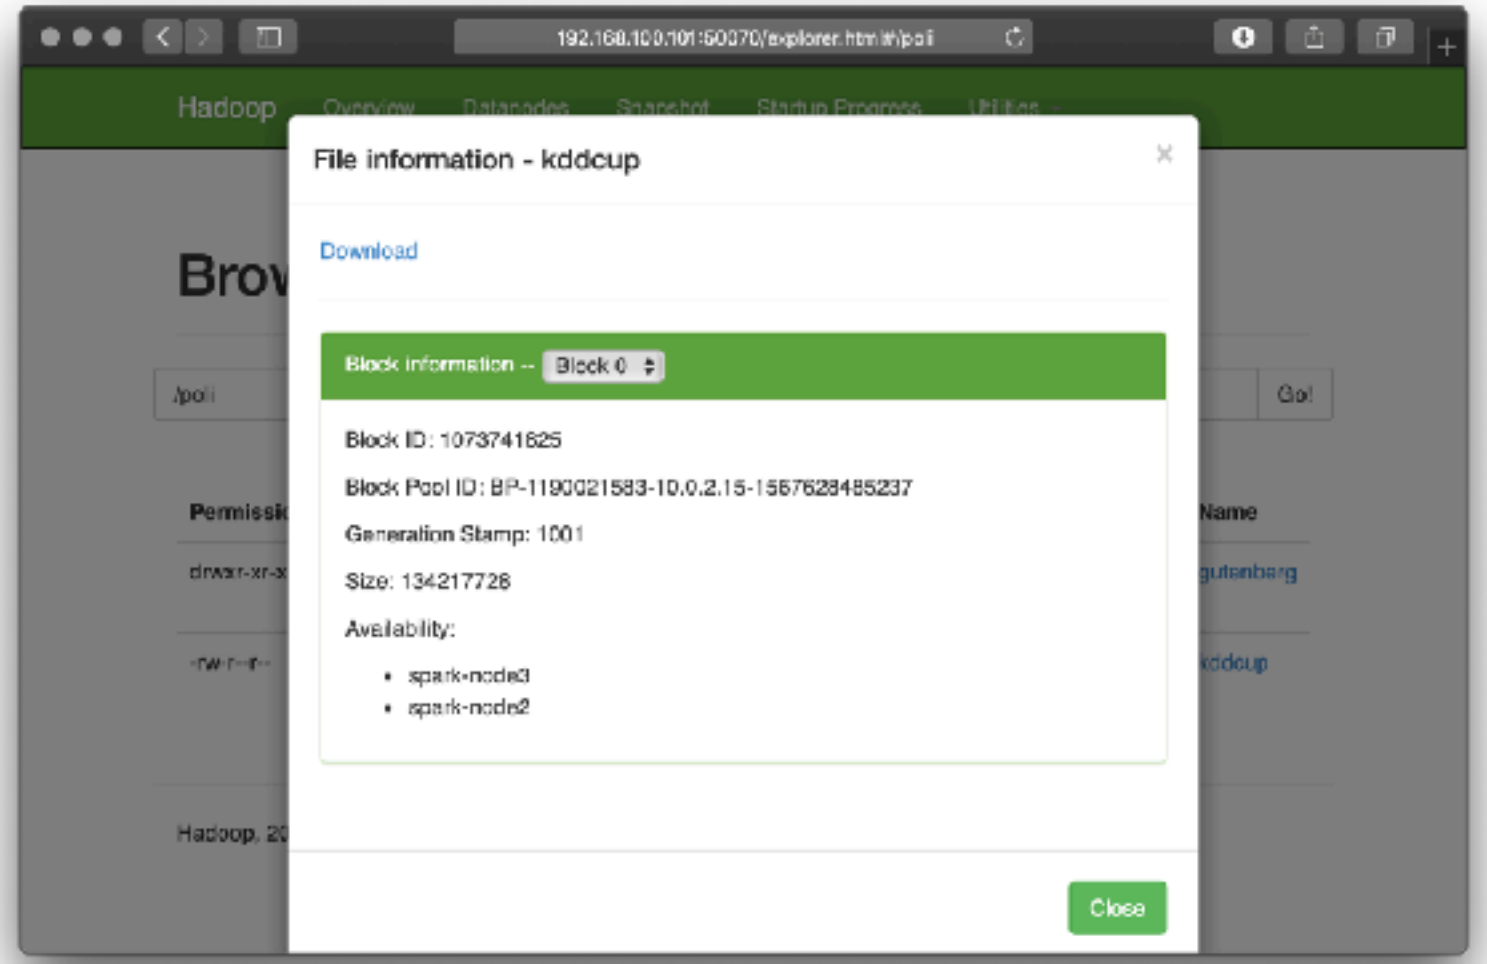

{ vamos praticar? }

- Crie uma pasta com suas iniciais no namenode
- mkdir <suas_iniciais>
- cd <suas_iniciais>

{ hadoop fs }

- Interage com diversos sistemas de arquivo
  - HDFS, HFTP, S3 FS etc
- hdfs dfs => sinônimo de hadoop fs para armazenamento HDFS

- Nesta aula, serão utilizados sem distinção

```
hadoop fs -rm /bigdata/input/big.txt

hdfs dfs -rm /bigdata/input/big.txt

hdfs dfs -rm hdfs:///bigdata/input/big.txt

hdfs dfs -rm hdfs://master:8020/bigdata/input/big.txt

…
```

{ criando pastas }

mkdir

hadoop fs -mkdir [-p] <paths>

- -p: cria pastas pai ao longo do caminho

```
$ hadoop fs -mkdir -p /bigdata/gutenberg/
$ hadoop fs -mkdir -p /bigdata/noticias/
$ hadoop fs -mkdir -p /bigdata/kddcup/
$ hadoop fs -mkdir -p /bigdata/pt7/
```

{ enviando arquivos **para** o cluster }

copyFromLocal ou put

```
hadoop -copyFromLocal [-f] [-t <thread count>] <localsrc>
URI
```

- -f: sobrescreve o destino, se existir
- -t <thread count> : número de threads a serem utilizadas na operação

```
$ hadoop fs -copyFromLocal gutenberg/*.txt /bigdata/gutenberg
$ hadoop fs -copyFromLocal noticias/*.txt /bigdata/noticias
$ hadoop fs -put pt7/*.parquet /bigdata/pt7
$ hadoop fs -put kddcup.data /bigdata/kddcup
```

{ contando itens }

count

hadoop fs -count [-h] [-v] URI

- -h : formato legível para humanos
- -v : exibe cabeçalho das informações

```
$ hadoop fs -count -h -v /
$ hadoop fs -count -h -v /bigdata/pt7
```

{ copiando dados **NO** cluster }

cp

```
hadoop fs -cp [-f] [-t <thread count>] URI [URI ...] <dest>
```

- -f: sobrescreve o destino, se existir
- -t <thread count> : número de threads a serem utilizadas na operação

```
$ hadoop fs -mkdir -p /<<minha_pasta>>/data
$ hadoop fs -cp -f -t 4 /bigdata/ /<<minha_pasta>>/data
```

{ listagem de arquivos }

ls

```
hadoop fs -ls [-d] [-h] [-R] <args>
```

- -d: apenas o diretório
- -h: formata o tamanho do arquivo
- -R: busca recursiva

```
$ hadoop fs -ls -h -R /bigdata/
```

{ visualizando conteúdo }

ls

```
hadoop fs -head < pathname >
```

```
$ hadoop fs -head /bigdata/noticias/noticia1.txt
```

{ recuperando arquivos **do** cluster }

copyToLocal ou **get**

```
hadoop fs -copyToLocal [-f] [-t <thread count>] <localsrc> URI
```

- `-f: sobrescreve o destino, se existir`
- `-t <thread count> : número de threads a serem utilizadas na operação`

```
$ hadoop fs -copyToLocal -f /bigdata/kddcup/kddcup.data /user_data
```

CUIDADO: a máquina destino pode não ter capacidade para receber o **BIG** arquivo.

{ espaço livre no cluster }

df

```
hadoop fs -df -h
```

- -h : formato legível para humanos

```
$ hadoop fs -df -h
```

{ modificando o tamanho padrão do bloco }

put

```
hadoop fs -D dfs.block.size=xxx -put <localsrc> URI
```

```
$ hadoop fs -D dfs.block.size=67108864 -put kddcup.data /bigdata/
kddcup/kddcup64M.data
```

```
$ hadoop fs -D dfs.block.size=67108864 -cp /bigdata/kddcup/
kddcup.data /bigdata/kddcup/kddcup64M.data
```

{ modificando o número de réplicas }

setrep

```
hadoop dfs -setrep -w -R xxx URI
```

- `-w: prompt espera até o final da operação`

```
$ hadoop fs -setrep -w N /bigdata/kddcup/kddcup.data
```

Obs: a diminuição de réplicas é um processo mais moroso que a adição.

{ referência completa }
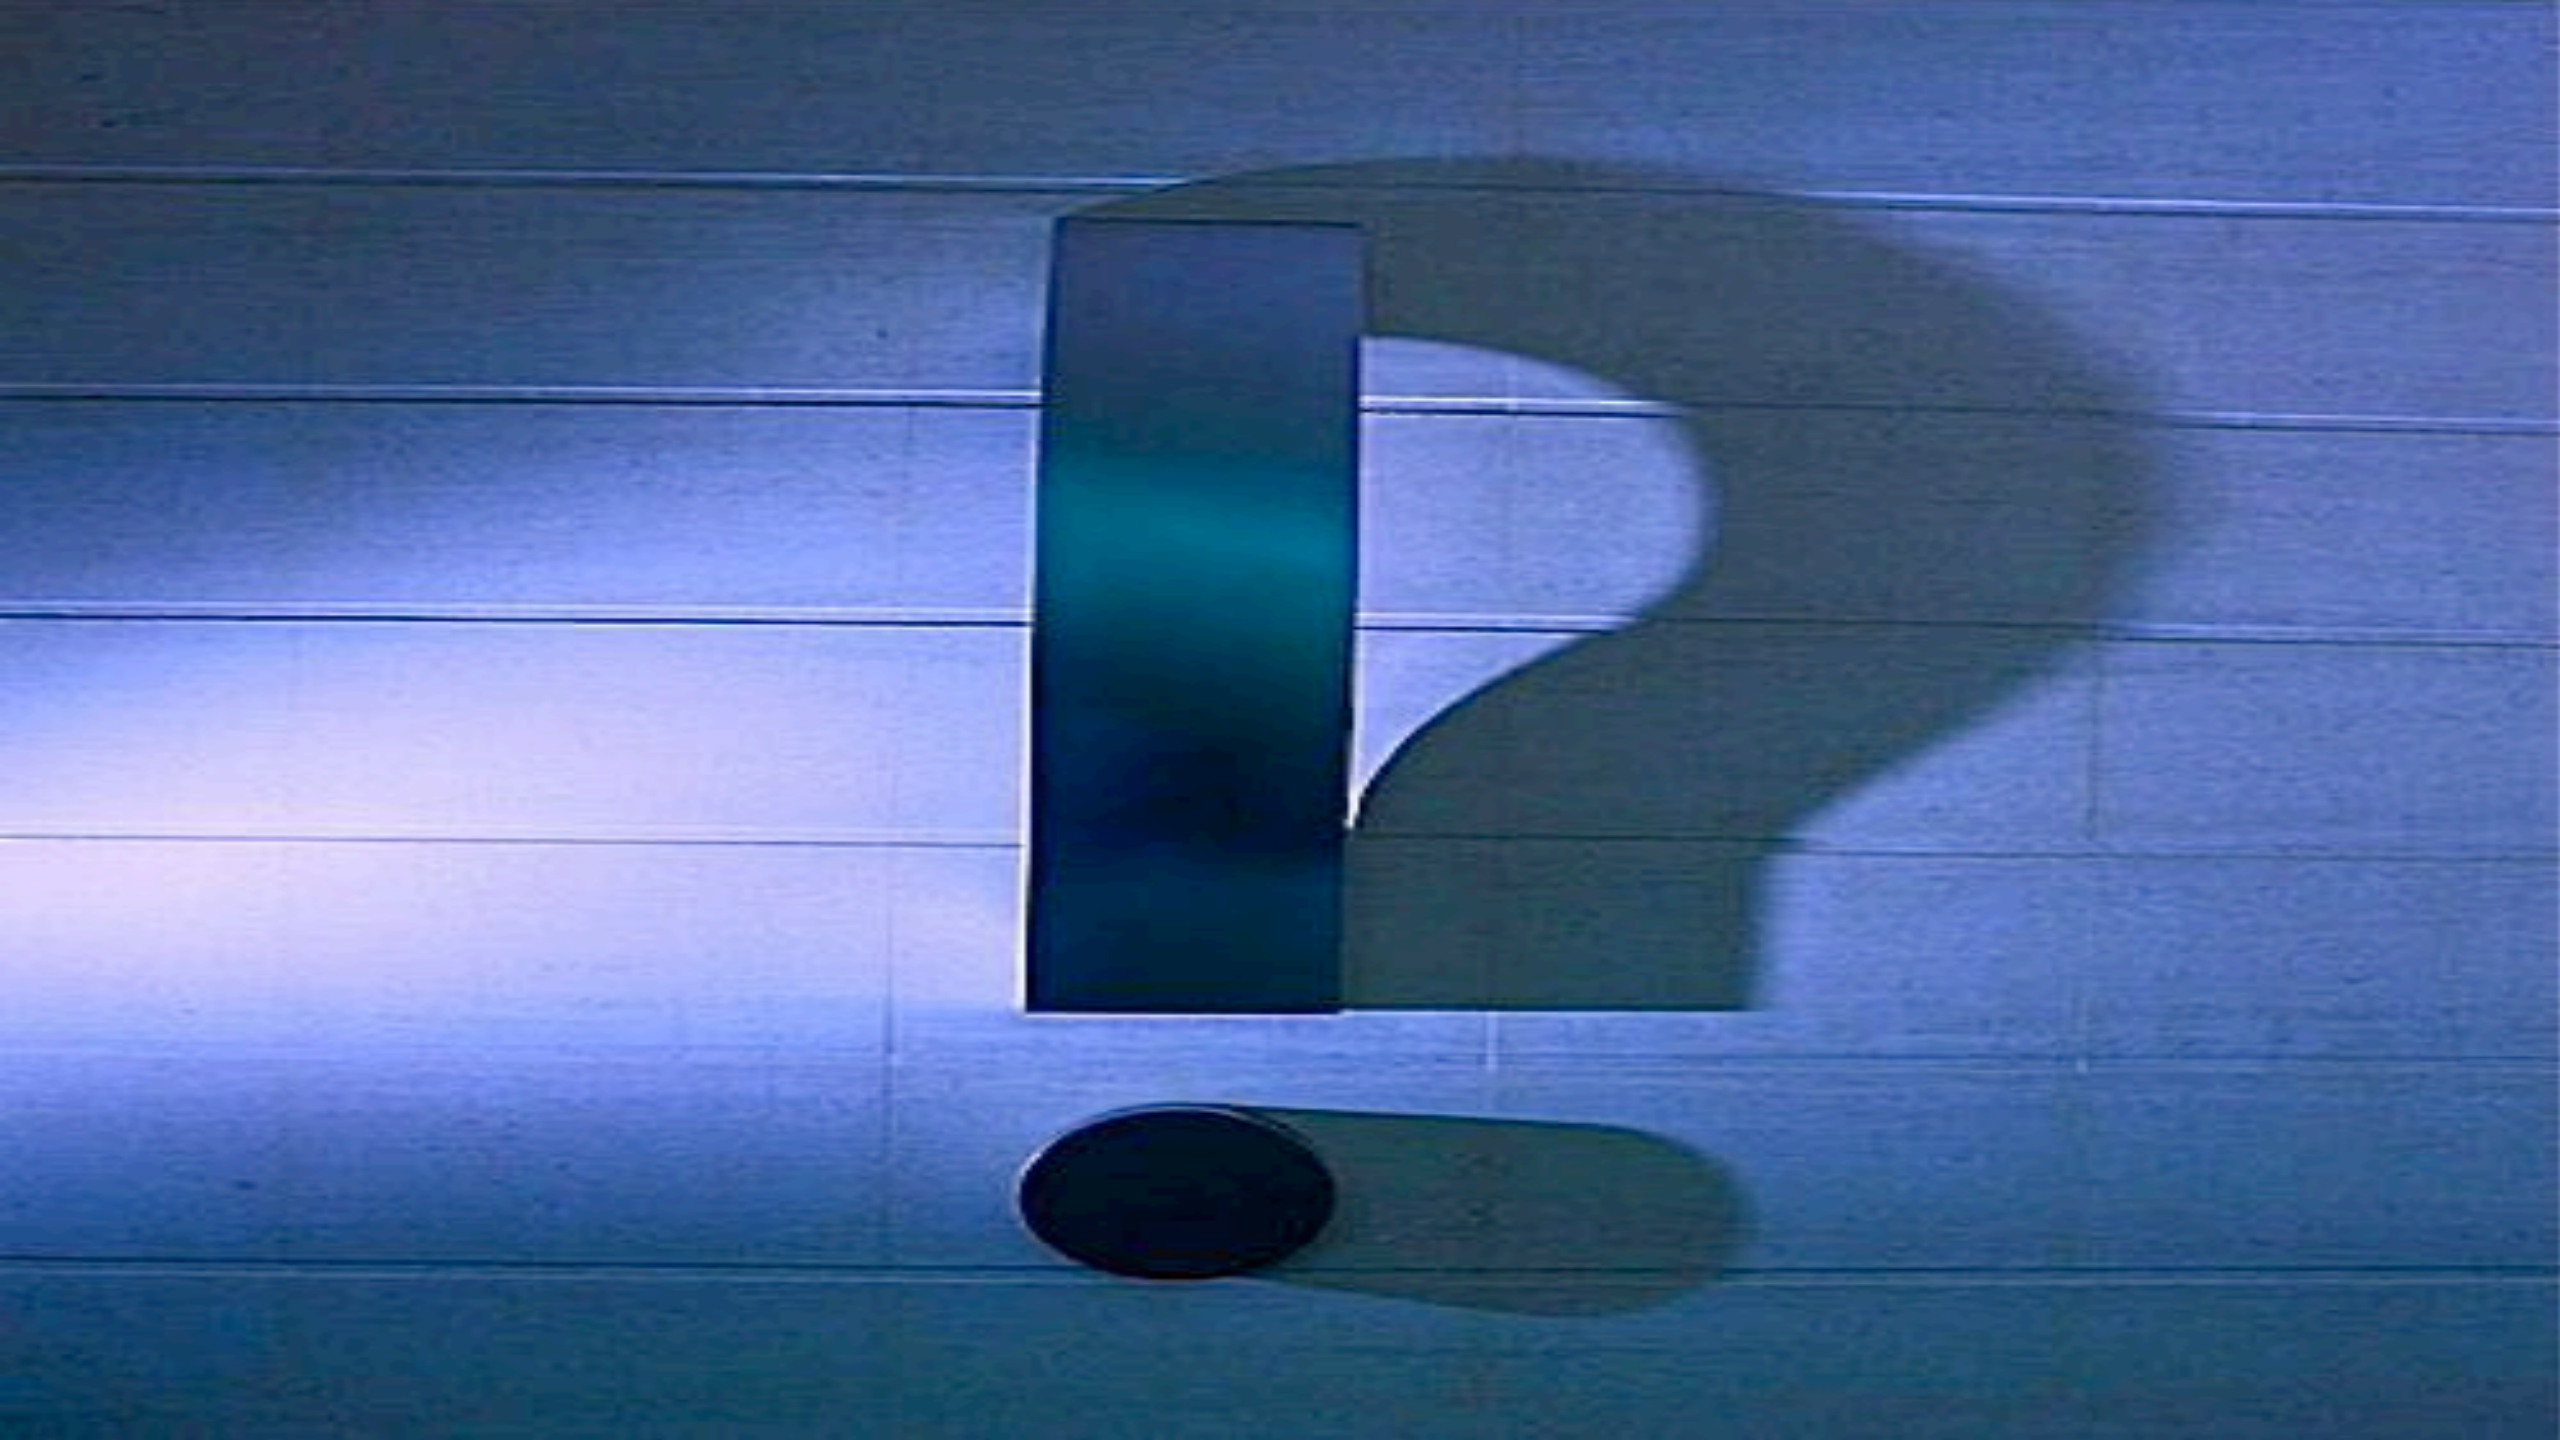
- Shell
  - https://hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-common/FileSystemShell.html
- Outros Comandos
  - https://hadoop.apache.org/docs/current/hadoop-project-dist/hadoop-hdfs/HDFSCommands.html
- Guia do Usuário HDFS
  - https://hadoop.apache.org/docs/current/hadoop-project-dist/hadoop-hdfs/HdfsUserGuide.html